INFORME METODOLÓGICO

Minería de Datos I | Proyecto de Aula ObraTech

1. Introducción y problema

ObraTech propone una plataforma para conectar clientes, constructoras, contratistas y trabajadores del sector de la construcción en Colombia. Busca apoyar la publicación de proyectos, las postulaciones, la contratación y el seguimiento de obras. Este ejercicio explora si los datos públicos de contratación pueden aportar un primer análisis de patrones contractuales relacionados con el estado registrado de los contratos.

Pregunta de análisis: ¿Qué características registradas de los contratos se relacionan con su estado contractual en el dataset seleccionado? El alcance es exploratorio: no se pretende afirmar que los datos representen todos los proyectos de construcción ni que el modelo permita evaluar directamente a una persona contratista.

2. Fuente y descripción de los datos

La fuente utilizada es el dataset “CCE SECOP II” publicado en Datos Abiertos de Colombia: https://www.datos.gov.co/Gastos-Gubernamentales/CCE-secop-ii/tjbh-5nnb. El archivo CSV recibido contiene **4,400 registros y 67 columnas**. Incluye atributos de entidad, localización, tipo y modalidad de contrato, estado, fechas, valores económicos, información del proveedor y campos administrativos.

Para reducir riesgos de privacidad y evitar variables que no aportan a la pregunta, el modelado no utiliza nombres de personas, números de identificación, direcciones, NIT ni códigos de proveedor/contrato como predictores. El dataset público contiene campos personales y administrativos que no deben copiarse innecesariamente al repositorio.

Una limitación central se detectó al perfilar los registros: los 4.400 contratos del archivo corresponden al Distrito Capital de Bogotá y al sector Planeación. Por ello, el archivo no representa la contratación nacional ni se limita a obras de construcción. La descripción del proceso contiene menciones a “construcción” o “infraestructura”, pero varias se refieren a sistemas tecnológicos, mantenimiento u otros contextos. La fuente es útil para practicar minería de datos, pero su pertinencia para el dominio completo de ObraTech es parcial.

3. Metodología y herramientas

Se siguió una secuencia inspirada en las seis etapas de la guía de la asignatura: definir el problema, revisar los datos, preparar variables, modelar, evaluar y reportar. El análisis estadístico y el experimento de clasificación se ejecutaron con Python, pandas y scikit-learn. Esta ejecución no equivale a afirmar que se completaron pantallas o evidencias de MinedApp; el equipo debe incorporar capturas de esa aplicación si la guía del docente las exige.

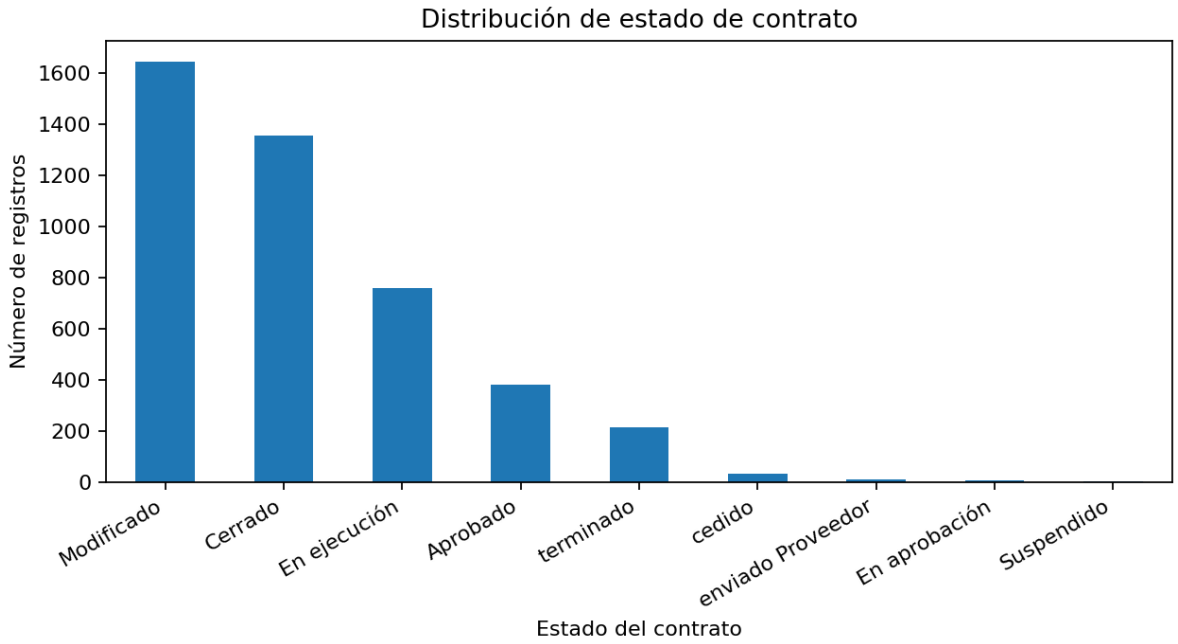
4. Exploración y preparación

El archivo contiene 4,400 filas y 67 columnas. No se encontraron filas completamente duplicadas. En las variables principales, “Fecha de Firma” presenta 16 valores faltantes y “Fecha de Inicio del Contrato” presenta 102. La fecha de firma abarca desde el 11/06/2015 hasta el 09/10/2026.

El estado registrado más frecuente es “Modificado” (1.645 registros), seguido de “Cerrado” (1.357), “En ejecución” (758), “Aprobado” (381) y “terminado” (212). Los estados “cedido”, “enviado Proveedor”, “En aprobación” y “Suspendido” son poco frecuentes. Para el primer modelo se conservaron las cinco clases con al menos 100 registros, quedando 4.353 observaciones para el experimento. Esta decisión reduce la

representación de estados raros y limita las conclusiones sobre ellos.

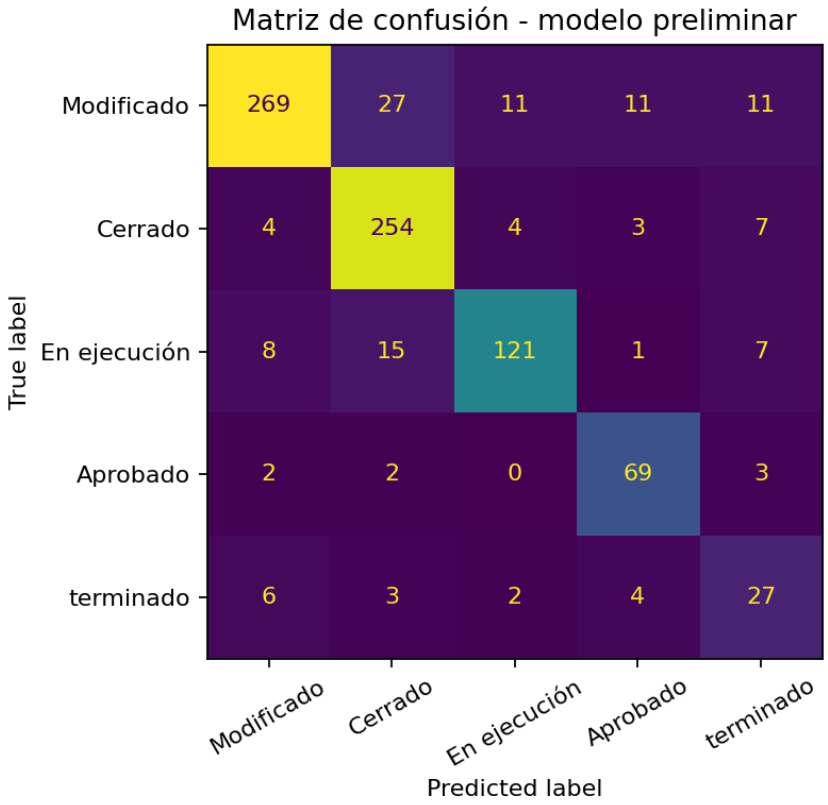
El valor del contrato presenta una distribución muy asimétrica: la mediana es aproximadamente $22,833,334, mientras que el máximo ronda $10,662,952,293. Los valores cero y los valores muy elevados deben interpretarse según la naturaleza de cada contrato, no eliminarse automáticamente como errores. Los valores monetarios se convirtieron a formato numérico; las fechas se transformaron en fechas y de ellas se derivaron el mes y año de firma, días entre firma e inicio y duración planeada.



5. Modelo y evaluación

La variable objetivo fue “Estado Contrato”. Se entrenó un Random Forest Classifier con 80 % de los registros para entrenamiento y 20 % para prueba, usando partición estratificada y semilla 42. Las variables predictoras incluyeron tipo y modalidad de contrato, justificación de modalidad, condiciones de entrega, indicadores administrativos, destino y origen de recursos, valor del contrato, días adicionados y variables derivadas de fechas. Los datos categóricos se codificaron con one-hot encoding y los valores faltantes se imputaron mediante la categoría más frecuente o la mediana, según el tipo de variable.

Accuracy: 0.8496 (84.96 %). **F1 macro:** 0.7980. **Referencia de clase mayoritaria:** accuracy 0.3777 (37.77 %), F1 macro 0.1097. La diferencia indica que el modelo distingue mejor las cinco clases en esta partición que la referencia simple.



El desempeño varía por clase: la clase “terminado” obtuvo un F1 aproximado de 0,56, inferior a las demás clases, por lo que las predicciones para esa categoría requieren especial cautela. Estas métricas describen únicamente una partición de prueba del archivo recibido; no garantizan el mismo rendimiento con datos nuevos, otras entidades o proyectos de construcción. Además, el estado contractual es una etiqueta administrativa existente, no una medida directa de calidad, retraso, satisfacción o confiabilidad del contratista.

6. Resultados e interpretación

El experimento demuestra que es técnicamente posible preparar variables mixtas y entrenar un clasificador para distinguir cinco estados contractuales frecuentes dentro de esta muestra. El resultado preliminar de 84,96 % de accuracy es superior al 37,77 % de la referencia de clase mayoritaria. Sin embargo, debe interpretarse como un resultado de prueba sobre una muestra limitada, no como evidencia de que ObraTech ya pueda predecir el desempeño futuro de obras.

Para ObraTech, el aprendizaje más importante es metodológico: antes de desarrollar una función predictiva, debe asegurarse que el dataset represente el problema real. Un dataset de contratos de la entidad Colombia Compra Eficiente en Bogotá no permite sacar conclusiones generales sobre todos los clientes, contratistas, trabajadores y obras del país.

7. Limitaciones y conclusiones

Las principales limitaciones son: (1) cobertura geográfica e institucional restringida; (2) falta de enfoque exclusivo en obras; (3) estados raros excluidos del primer modelo; (4) ausencia de validación temporal o externa; (5) posible cambio de definiciones o calidad en el portal; y (6) el estado actual del contrato no equivale a una variable objetiva de retraso o calidad de obra. Por ello, el modelo se presenta como prototipo académico exploratorio.

Se recomienda, para una versión posterior, conseguir datos con mayor correspondencia al sector construcción y variables explícitas de obra, presupuesto, fecha planeada y real de terminación, modificaciones, retrasos y

estado de ejecución. Para un modelo de predicción de retrasos sería imprescindible definir una variable objetivo verificable y validar que la información usada estaría disponible antes del evento que se quiere anticipar.

8. Referencias y repositorio

Datos Abiertos de Colombia. (s. f.). *CCE SECOP II*. https://www.datos.gov.co/Gastos-Gubernamentales/CCE-secop-ii/tjbh-5nnb

Datos Abiertos de Colombia. (s. f.). *SECOP II - Contratos Electrónicos*. https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h/about_data

Cuadrado Beltrán, C. C. (s. f.). *Guía práctica para completar los entregables del proyecto de aula*. Minería de Datos I. Documento proporcionado por el equipo.

Repositorio: pendiente de completar con el enlace real del equipo. La carpeta de trabajo generada incluye README, script y notebook para que el equipo los revise y los publique en su repositorio.