INFORME METODOLÓGICO

Minería de Datos | Proyecto de Aula ObraTech

1. Introducción y Definición del Problema

ObraTech es una plataforma orientada a conectar clientes, constructoras, contratistas y trabajadores de la construcción en Colombia. Busca apoyar la publicación de proyectos, postulaciones, contratación y seguimiento de obras. Este ejercicio explora cómo los datos públicos de contratación pueden aportar un análisis de patrones contractuales relacionados con el estado registrado de los contratos.

- **Nombre del proyecto:** ObraTech
- **Pregunta de análisis:** ¿Qué características registradas de los contratos se relacionan con su estado contractual actual en el dataset seleccionado?
- **Tipo de tarea:** Clasificación multiclase
- **Variable objetivo:** `Estado Contrato`

2. Fuente y Descripción de los Datos

La fuente de datos utilizada es el dataset "CCE SECOP II" publicado en Datos Abiertos de Colombia (dataset `CCE_secop_ii_20261013.csv`).

Parámetro	Detalle
Volumen	4,400 registros (filas) y 67 columnas
Variables Numéricas (5)	Documento Proveedor, Saldo Vigencia, Días adicionados, Recursos Propios, Código Proveedor
Variables Categóricas (62)	Nombre Entidad, NIT Entidad, Departamento, Ciudad, Localización, Orden, Sector, Rama, Tipo de Contrato, Modalidad de Contratación, Justificación Modalidad, Condiciones de Entrega, Es Pyme, Habilita Pago Adelantado, Liquidación, Obligación Ambiental, Origen de Recursos, Destino Gasto, Valor del Contrato, entre otras

Parámetro	Detalle
Calidad de datos	16 registros nulos en Fecha de Firma y 102 en Fecha de Inicio del Contrato. Los 4,400 registros corresponden al Distrito Capital de Bogotá y al sector Planeación
Privacidad	Exclusión de identificadores personales, nombres de representantes legales, documentos y direcciones como predictores

3. Preprocesamiento de Datos

A través de la herramienta MinedApp, se configuraron y aplicaron las siguientes técnicas de preparación:

- **Tratamiento de Nulos:** Imputación con la mediana para variables numéricas (`Imputar con mediana`).
- **Tratamiento de Outliers:** Winsorización limitada a los percentiles 5% y 95% (`clip(0.05, 0.95)`), controlando la asimetría de los valores monetarios sin perder registros.
- **Escalado de Variables Numéricas:** Aplicación de `StandardScaler` (media=0, std=1).
- **Codificación Categórica:** Aplicación de `One-Hot Encoding` (`pd.get_dummies`) para transformar categorías en variables binarias.

4. Modelado Predictivo

- **Algoritmo seleccionado:** `Random Forest Classifier`
- **División de Datos:** 80% para entrenamiento (`X_train`, `y_train`) y 20% para prueba (`X_test`, `y_test`).
- **Configuración:** Partición estratificada (`stratify=y`) y semilla aleatoria fija (`random_state=42`).
- **Justificación:** Random Forest permite capturar relaciones complejas y no lineales entre variables categóricas y numéricas, resultando altamente robusto como modelo baseline de clasificación.

5. Evaluación del Modelo

El modelo fue evaluado mediante las siguientes métricas de rendimiento en clasificación multiclase:

Métrica	Resultado	Referencia / Observación
Accuracy (Exactitud global)	**84.96%** (0.8496)	Frente a 37.77% de la clase mayoritaria
F1-Score Macro	**0.7980**	Promedio no ponderado entre clases
Métricas complementarias	Precision, Recall, Matriz de Confusión	Evaluación detallada por categoría

- **Interpretación:** El modelo logra distinguir con alta precisión las clases principales ("Modificado", "Cerrado", "En ejecución", "Aprobado"), aunque presenta menor desempeño en la clase "terminado" (F1 ~0.56).

6. Conclusiones y Recomendaciones

1. Es técnicamente viable entrenar un clasificador multiclase para analizar estados contractuales con un 84.96% de exactitud.
2. El aprendizaje principal para ObraTech es metodológico: para llevar el modelo a producción, se requiere recolectar datos nativos específicos del sector construcción a nivel nacional (tiempos de obra, imprevistos, calificaciones).