PROPUESTA DEL MODELO PREDICTIVO

Proyecto de Aula: ObraTech
Asignatura: Minería de Datos I

Campo	Información
Nombre del proyecto	ObraTech
Integrantes	[Completar con los nombres del equipo]
Repositorio	[Agregar enlace del repositorio GitHub/GitLab del equipo]
Fecha	13 de octubre de 2026
Fuente de datos	Dataset CCE SECOP II, portal Datos Abiertos de Colombia

A. Problema

ObraTech es una plataforma orientada al sector de la construcción en Colombia que busca conectar clientes, constructoras, contratistas y trabajadores, facilitando la publicación de proyectos, las postulaciones, la contratación y el seguimiento de las obras. Para fortalecer la toma de decisiones basada en datos, se plantea explorar información pública de contratación y evaluar si los atributos de los contratos permiten identificar patrones asociados con su estado registrado.

Pregunta de análisis: ¿Qué características registradas de los contratos se relacionan con su estado contractual en el dataset seleccionado?

El análisis puede servir como ejercicio inicial para comprender patrones de contratación pública y orientar futuras funcionalidades analíticas de ObraTech. No equivale a medir directamente la calidad de los contratistas ni el desempeño de las obras privadas.

B. Datos

Fuente: CCE SECOP II, Datos Abiertos de Colombia. https://www.datos.gov.co/Gastos-Gubernamentales/CCE-secop-ii/tjbh-5nnb.

Archivo analizado: CSV proporcionado por el equipo, con 4,400 registros y 67 columnas.

Variables candidatas: Estado Contrato (objetivo), Tipo de Contrato, Modalidad de Contratación, Justificación de Modalidad, Condiciones de Entrega, Es Pyme, Habilita Pago Adelantado, Liquidación, Obligación Ambiental, Destino del Gasto, Origen de los Recursos, Valor del Contrato, Días adicionados y variables derivadas de fechas.

Calidad inicial: en las variables seleccionadas, 16 registros no tienen Fecha de Firma y 102 no tienen Fecha de Inicio del Contrato. No se encontraron filas completamente duplicadas. Se requiere normalizar fechas y valores monetarios.

Limitación importante: el archivo recibido contiene 4.400 filas, todas asociadas al Distrito Capital de Bogotá y al sector Planeación. Por tanto, no representa por sí solo el conjunto de proyectos de construcción de Colombia.

Una búsqueda por palabras clave encontró coincidencias textuales con términos como “obra”, “construcción” o “infraestructura”, pero estas también incluyen mantenimiento de sistemas y otros usos no constructivos.

C. Modelo propuesto

Tipo de tarea: clasificación multiclase exploratoria del estado contractual registrado.

Variable objetivo: Estado Contrato. Para el primer experimento se conservaron las cinco clases con al menos 100 observaciones: Modificado, Cerrado, En ejecución, Aprobado y terminado. Las clases menos frecuentes se excluyeron únicamente del entrenamiento inicial por su baja representación y deben revisarse en una iteración futura.

Algoritmo: Random Forest Classifier, con codificación one-hot de variables categóricas e imputación de valores faltantes. Se usa una partición estratificada de 80 % para entrenamiento y 20 % para prueba, con semilla aleatoria 42. Se excluyen identificadores, nombres, documentos y direcciones personales como variables predictoras.

Justificación: Random Forest puede modelar relaciones no lineales entre variables categóricas y numéricas y no requiere escalar los valores numéricos para este caso. Se propone como línea base de modelado, no como sistema de decisión listo para producción.

D. Evaluación

Se reportan exactitud (accuracy), F1 macro y métricas por clase. Como referencia sencilla se compara con un clasificador que siempre predice la clase mayoritaria. Las métricas presentadas corresponden a una ejecución preliminar realizada sobre la muestra recibida; deben reproducirse y revisarse por el equipo en su entorno.

E. Resultado esperado y limitaciones

Se espera identificar si las variables contractuales seleccionadas contienen señales útiles para distinguir estados registrados y documentar qué variables y categorías requieren revisión. El experimento preliminar obtuvo accuracy de 84,96 % y F1 macro de 0,798; el clasificador de referencia obtuvo accuracy de 37,77 %. Estos resultados no prueban que el modelo prediga el futuro ni que generalice a otras entidades.

La limitación principal es la baja correspondencia entre el dataset recibido y el alcance completo de ObraTech. Antes de utilizar el modelo en una funcionalidad real, se recomienda conseguir datos más directamente relacionados con obras de construcción, ejecución, retrasos, presupuestos y contratistas, y validar el modelo en datos independientes.

Referencias

Datos Abiertos de Colombia. (s. f.). *CCE SECOP II*. https://www.datos.gov.co/Gastos-Gubernamentales/CCE-secop-ii/tjbh-5nnb

Datos Abiertos de Colombia. (s. f.). *SECOP II - Contratos Electrónicos*. https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h/about_data

Cuadrado Beltrán, C. C. (s. f.). *Guía práctica para completar los entregables del proyecto de aula*. Minería de Datos I. Documento proporcionado por el equipo.